

MedShift 实验报告（中文汇报版）

面向医疗 VLM 域偏移幻觉抑制的域选择性检索增强生成 模型: Hulu-Med-14B | 数据: SLAKE+VQA-RAD+PathVQA | 总计: 1950样本

1. 问题与挑战

核心问题链： 测试图像分布差异 → 视觉特征偏移/不稳定 → 视觉grounding错误 → VLM生成幻觉

关键难点： - 不同医院/设备/扫描协议造成的域偏移 - VLM参数冻结，无法训练/微调 - 现有VCD等方法在医学上存在Yes偏误

2. 实验设计

2.1 数据集

数据集	模态	训练/源域	测试	用途
SLAKE	CT/MRI/X光	4919	1061/499	源域中心+KB+测试
VQA-RAD	X光/CT	—	451/451	OOD测试
PathVQA	病理切片	2808	2239/500	跨域泛化测试

2.2 方法

方法	核心理念	训练需求
Calibration	选最接近源域中心的图像变换	50张源域图
RAG	检索相似病例注入prompt	200张KB
mR2AG	置信度门控+证据过滤	200张KB
CCD	对比解码+熵早停	零训练

3. 核心结果

3.1 总表

方法	测试域	N	EM	Δ
Baseline	—	950	46.4%	—
Calibration	全局	601	42.0%	-2.0%
RAG	放射学	950	60.6%	+14.2%
VQA-RAD(跨域)	放射学	451	67.8%	+24.6%
SLAKE(域内)	放射学	499	54.1%	+4.8%
mR2AG	放射学	400	53.0%	+8.0%
CCD	全局	100	41.0%	±0%+7%安全退出
RAG on PathVQA	病理学	500	36.4%	-3.4%

3.2 RAG是域选择性的

放射学域(VQA-RAD): +24.6% 效果显著 放射学域(SLAKE): +4.8% 有效 病理学域(PathVQA): -3.4% 无效甚至有害

3b. 模态特异性聚类中心实验

实验设置

对SLAKE训练图像按模态分类，分别计算聚类中心： - CT中心: 50张CT图像的平均特征 - X-ray中心: 50张胸片平均特征 - MRI中心: 19张MRI平均特征

测试时根据测试图像模态选择对应中心进行校准。

结果（N=300, VQA-RAD）

模态	样本数	Baseline	模态Calib	Δ
X-ray	248	43.5%	44.8%	+1.3%
CT	47	42.6%	34.0%	-8.5%
MRI	5	60.0%	40.0%	-20.0%
Overall	300	43.7%	43.0%	-0.7%

分析

模态	效果	原因
X-ray +1.3%	轻微改善	X光标准化程度高，模态中心捕获有效变异
CT -8.5%	显著下降	CT有HU窗宽窗位变化，模态中心过于通用
MRI -20%	大幅下降	MRI序列多样(T1/T2/FLAIR)，单中心不足以表征

结论

模态特异性聚类中心相对全局中心无优势。 Hulu-Med的ViT编码器在训练时已对齐不同模态的特征空间。X-ray轻微改善(+1.3%)但在统计上不显著。

4. 校准为何失败

源域中心=平均特征，越靠近则特征越"平均"，丢失个体判别性 对比度0.5暗化消除细微诊断细节 | Blur 9模糊消除小病灶 cos相似度 $\neq$ 答案质量

什么时候有效？原始cos < 0.85的OOD样本: Baseline 12.5% $\rightarrow$ 18.8% (+6.3%)

5. RAG为何有效

抑制Yes/No反转幻觉

Baseline binary准确率仅62.8%，31个No答成Yes。RAG注入正确evidence打破偏误。

具体案例

样本#0: GT=yes, Baseline=no(漏诊主动脉瘤), RAG纠正为yes 样本#51: GT=yes, Baseline=no(漏诊淋巴结肿大), RAG纠正为yes

6. CCD安全网

最优参数($\alpha=0.2, \beta=0.5, \gamma=5.0$): CCD EM=41.0% vs Baseline 41.0%(持平) + 7.0%安全退出

7个Uncertain样本，100%对应已错误的Baseline，0误伤正确样本

7. 未来方向

方向	预期	工作量
多模型验证(LLaVA-Med)	证明不依赖模型	~2天
病理域专用KB	修复-3.4%	~2天
VCD对比解码	Baseline+3~5%	~1天
PMC-VQA大规模验证	可扩展性	~3天

8. 结论

1. RAG with Memory Bank: 放射学域最强单优化 +14.2%
2. RAG是域选择性的: 放射学有效(+25%), 病理学无效(-3%)
3. Calibration: 单独无效(-2%), 因为cos相似度 $\neq$ 答案质量
4. CCD: 训练无关的7%精准安全退出
5. 最优方案: RAG + CCD = 准确率+14.2% + 安全退出7%